

Mohamed Aziz Ben Romdhane

Ingénieur IA | Ingénieur Machine Learning

✉ Benromdhane.Aziz@esprit.tn

☎ +216 23 235 038

📍 Tunis, Tunisie

🌐 linkedin.com/in/mohamed-aziz-ben-romdhane

🐙 github.com/benromdhaneaziz

PROFIL

Ingénieur IA et Machine Learning : applications d'**IA générative** en production, systèmes d'**IA agentique**, pipelines **RAG** et API Python. Mise en production d'un agent IA de voyage doté de 27 outils et 28 endpoints en streaming, réduisant de 65% la construction d'un plan de séjour, et d'une plateforme d'extraction de contrats par LLM adossée à Oracle. Expérience en Python, FastAPI, LangGraph, LangChain, PyTorch, Hugging Face, bases vectorielles, Docker, tests automatisés et CI/CD, ainsi qu'en NLP, séries temporelles, détection d'anomalies et réseaux de neurones sur graphes.

FORMATION

Diplôme d'ingénieur en Data Science (Bac+5, équivalent Master)

Sep 2021 – Déc 2025

ESPRIT, École Supérieure Privée d'Ingénierie et de Technologies, Tunis

EXPÉRIENCES PROFESSIONNELLES

Ingénieur IA / Logiciel, Worldsoft

Févr. 2026 – Aujourd'hui

- Mise en production de l'**agent IA de voyage de l'application CurvaTrip** : **27 outils d'agent** et 28 endpoints en streaming (FastAPI), vols en direct sur le GDS en fiches tarifaires, plans de séjour et voix temps réel (Gemini Live) en **4 langues** dont le dialecte tunisien ; **plan ramené de 128 s à 44 s (-65%)**.
- Développement complet d'une **plateforme SaaS d'extraction de contrats par LLM** : un extracteur Gemini convertit les contrats PDF/DOCX en un schéma Oracle normalisé de 17 tables et un moteur déterministe tarife tout séjour, **supprimant la saisie manuelle**. 49 endpoints REST, traitement asynchrone, JWT multi-tenant avec SSO, interface React, **suites pytest dans la CI/CD GitLab**.
- Livraison d'un **tableau de bord analytique à 8 agents** (SQL, analyste, prévision, anomalies, segmentation, hôtel, vol, orchestrateur) sur LangGraph et DeepSeek : **52 endpoints REST** avec streaming SSE sur Oracle et une interface Angular 17, remplaçant les rapports SQL manuels par des KPI, graphiques et cartes en libre-service.

Technologies : Python, FastAPI, LangGraph, LangChain, Gemini, DeepSeek, Oracle, pytest, Angular, React, Flutter, Docker, GitLab CI/CD.

Développeur .NET (stage), Prosper Us

Juil. 2023 – Août 2023

- Développement de PharmaReport, une application ASP.NET Core MVC générant des rapports pharmaceutiques structurés : modules MedicalReport et ReportSheet sur migrations EF Core, en remplacement des documents rédigés à la main. **Technologies** : C#, ASP.NET Core, Razor Pages, EF Core, SQL.

Développeur Web (stage), AS2E : sites WordPress clients et automatisation des rapports internes récurrents avec Google Apps Script. **Technologies** : WordPress, PHP, JavaScript.

Juil. 2022 – Août 2022

PROJETS

Chatbot RAG de factures aériennes (personnel) | GitHub

Mai 2026

- Application **RAG** qui extrait et indexe le contenu des factures aériennes avec des embeddings Hugging Face dans une base vectorielle ChromaDB, et répond aux questions en langage naturel via Groq Llama 3 sous interface Streamlit.

Graphe de connaissances pour la gestion de projet (ESPRIT) | GitHub

Sep 2024 – Janv. 2025

- Entraînement d'un **RGCN** PyTorch pour la prédiction de liens sur un graphe de connaissances projet, classant les liens manquants entre tâches, ressources et dépendances sur un échantillon d'arêtes retenu ; embeddings BERT, recherche vectorielle Pinecone et GPT-4o mini pour les questions-réponses. **Technologies** : Python, PyTorch, RGCN, BERT, Pinecone.

Plateforme d'analyse BVMT, Bourse de Tunis (ESPRIT) | GitHub

Févr. 2024 – Juin 2024

- Plateforme Streamlit de **10 modules** sur 8 ans de données de marché (2016-2023) : prédiction du sens du cours (AdaBoost, Gradient Boosting), classification du risque, clustering DBSCAN + UMAP, prévision des dividendes avec Prophet et un **chatbot RAG** (LangChain, Llama 2, FAISS) sur des PDF de marché. **Technologies** : Python, Streamlit, Scikit-learn, Prophet, UMAP, LangChain, FAISS, MongoDB.

COMPÉTENCES TECHNIQUES

Intelligence Artificielle & Machine Learning : IA générative, IA agentique, grands modèles de langage (LLM), génération augmentée par la recherche (RAG), LangGraph, LangChain, orchestration multi-agents, prompt engineering, NLP, Transformers, BERT, Hugging Face, PyTorch, Scikit-learn, Pandas, NumPy, réseaux de neurones sur graphes | **Programmation** : Python, SQL / PL-SQL, Java, C#, TypeScript, Bash | **Back-end, déploiement de modèles & API** : FastAPI, mise en service de modèles, API REST, Spring Boot, ASP.NET Core, JWT, SSE, OpenAPI | **MLOps & ingénierie logicielle** : Docker, GitLab CI/CD, tests automatisés, pytest, Git, Linux, Prometheus, Grafana, logs et supervision | **Données & bases vectorielles** : Oracle, MySQL, MongoDB, FAISS, ChromaDB, Pinecone

CERTIFICATIONS

- Building Transformer-Based Natural Language Processing Applications, NVIDIA, 2024
- Natural Language Processing Specialization (4 cours), DeepLearning.AI sur Coursera, 2024
- Microsoft Azure, cursus fondamentaux (3 cours), Microsoft sur Coursera, 2024

LANGUES

Arabe : Langue maternelle | **Français** : Courant | **Anglais** : Avancé